Vorlesung

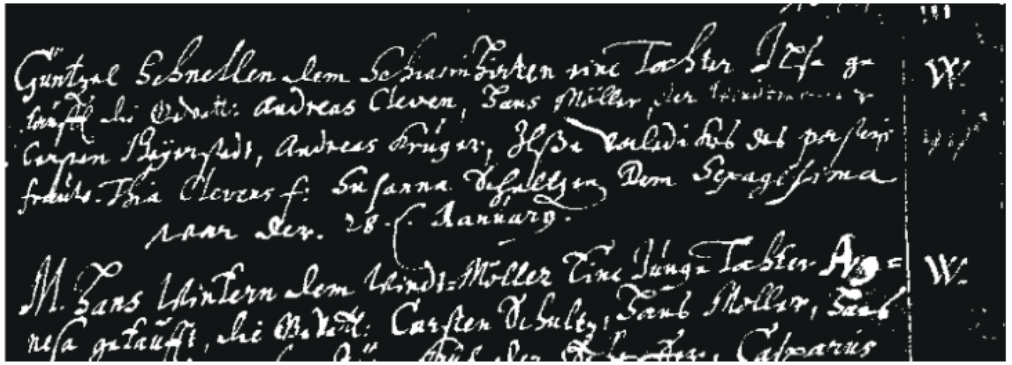
Bildverarbeitung

Dr. Frank Stollmeier & Prof. Dr.-Ing. Hanno Homann

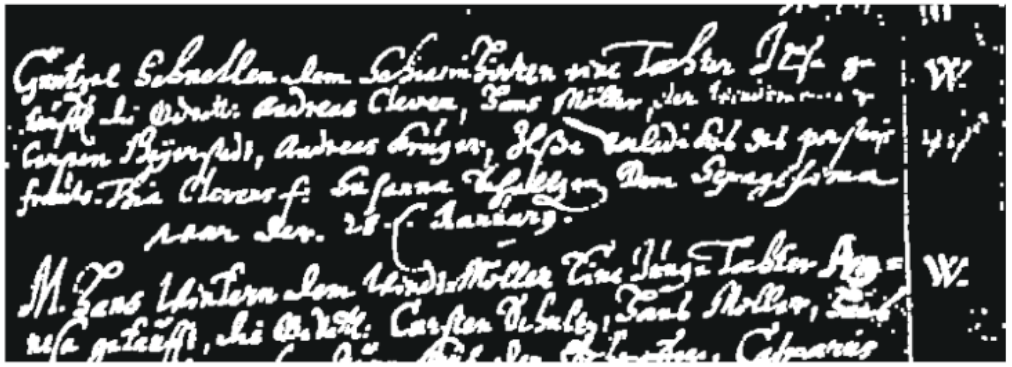
© Alle Rechte vorbehalten. Weitergabe nur mit ausdrücklicher schriftlicher Genehmigung des Vortragenden.

Morphologische Operatoren

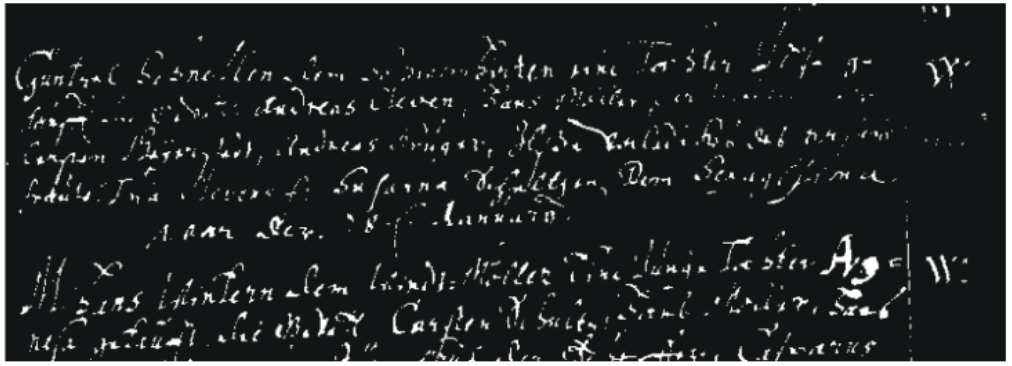
Binärbild



Dilatation

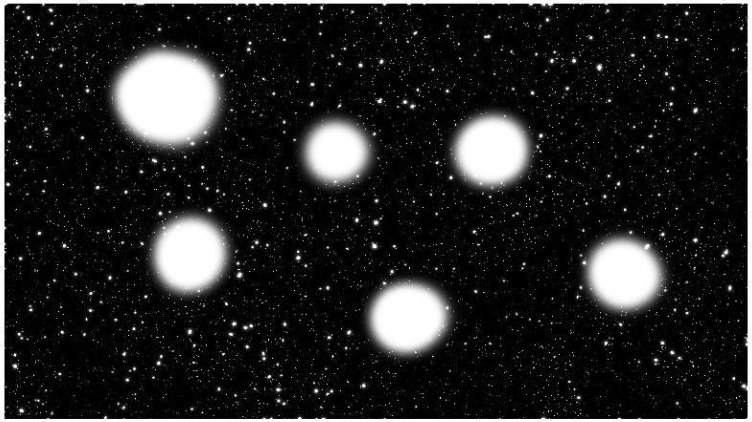


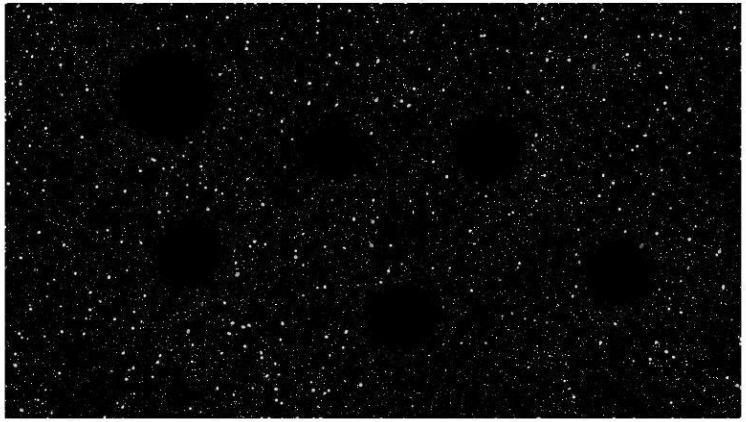
Erosion



Rohs / Kratz, LMU München

Morphologische Operationen

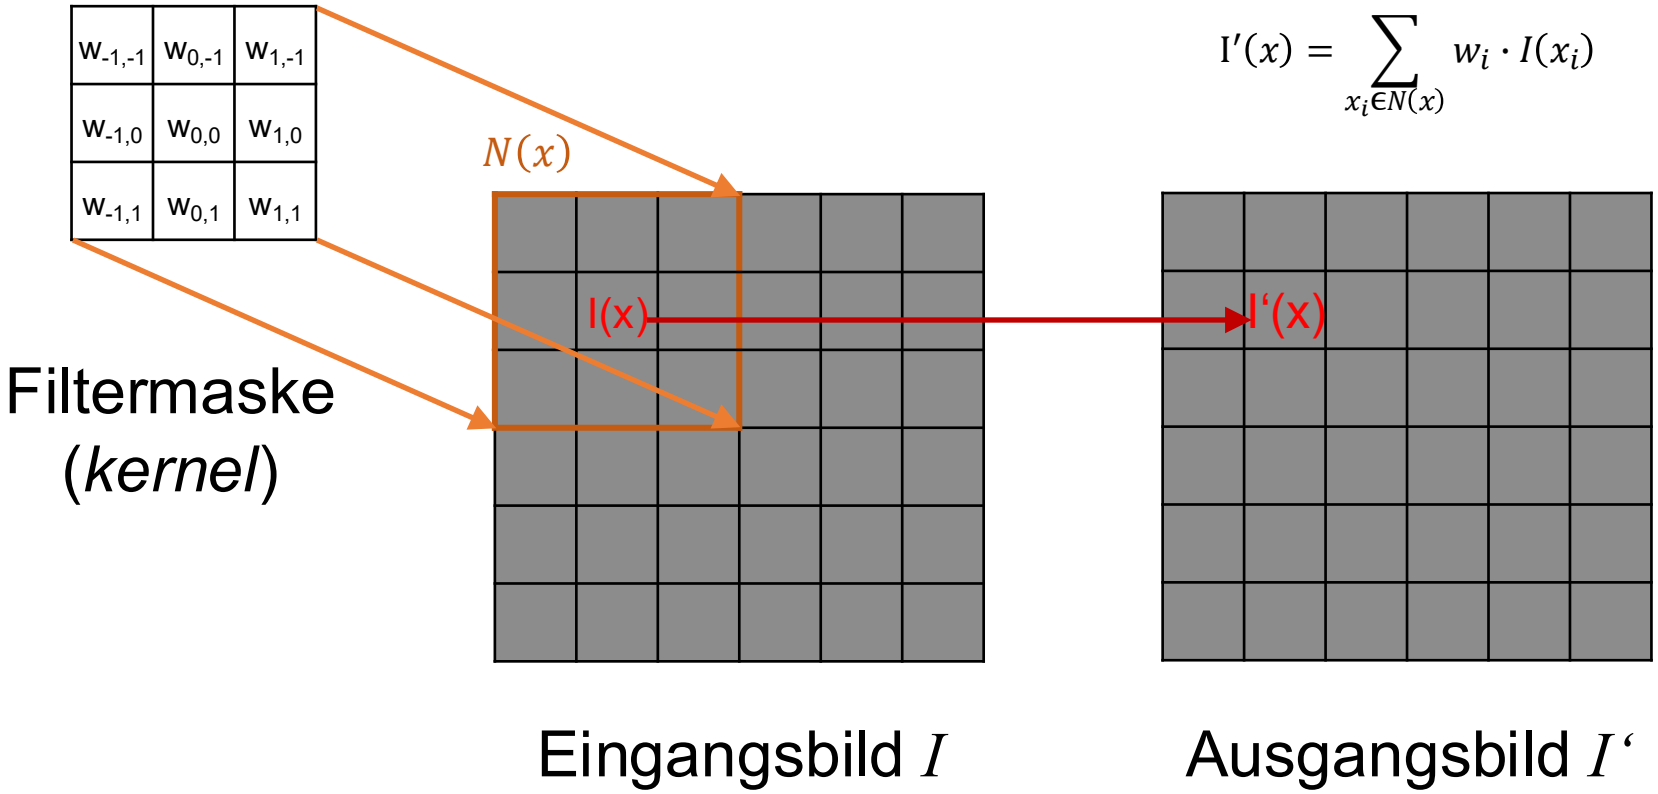




Top-hat transform $T(I) = I - I \circ b$

Bilder: https://commons.wikimedia.org/wiki/File:Cosmos_tophat.jpg
https://commons.wikimedia.org/wiki/File:Cosmos_original.jpg

Faltungsoperation



$$I'(x) = \sum_{x_i \in N(x)} w_i \cdot I(x_i)$$

Rauschunterdrückung: Binomial-Filter und Mittelwertfilter



Verrauschtes Eingangsbild
(Gauss, σ_I=50)



3x3 Binomial-Kernel



5x5 Binomial-Kernel



3x3 Mittelwert-Kernel



5x5 Mittelwert-Kernel

Kapitel V

- Merkmalsextraktion -

Inhalt

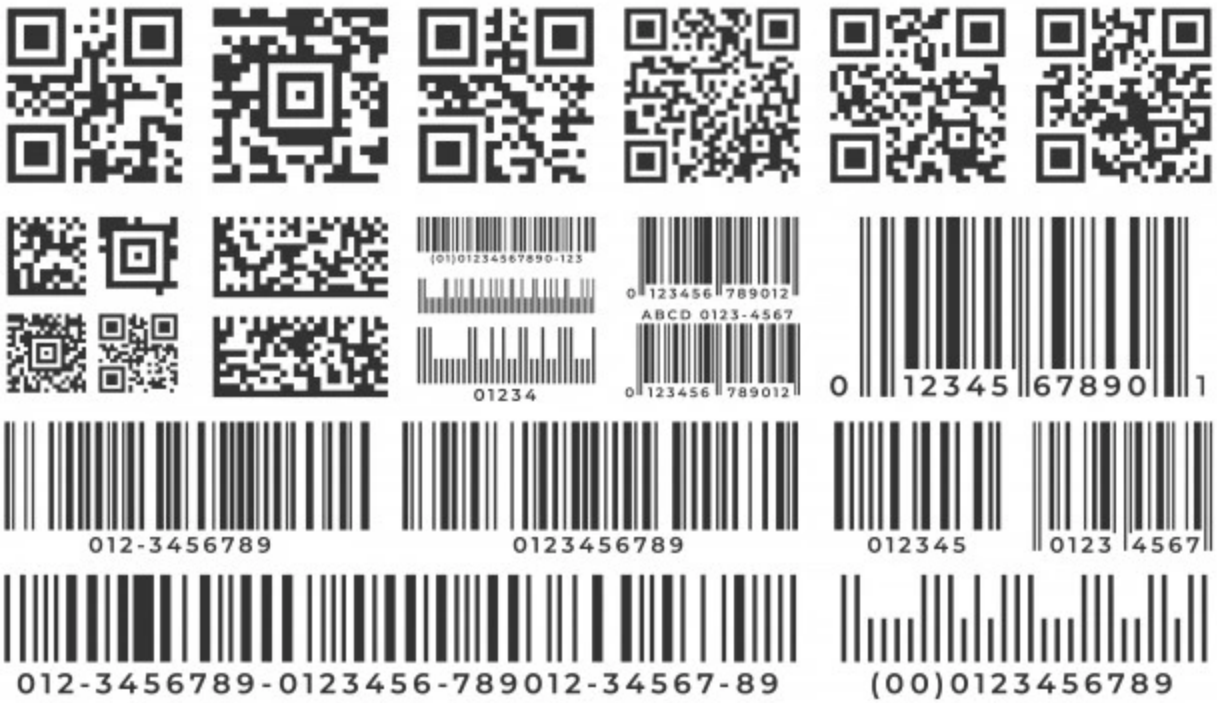
- Lokale Ableitung mit Filter-Operatoren
- Kantendetektion (Prewitt, Sobel, Canny)
  - Anwendung: Spurmarkierungen
- Ecken-Detektoren (Harris, FAST)
- Ecken-Descriptoren (BRIEF)
  - Anwendung: Image stitching, optical flow

Was sind Merkmale (*features*) in Bildern?

- Relevante lokale Muster
- Vorverarbeitungs-Schritt für Detektion und Segmentierung von Objekten
- Beispiele
  - Kanten
  - Ecken
  - Linien
  - Textur

Anwendungen

Bar-Codes, QR-Codes, ISBN, …

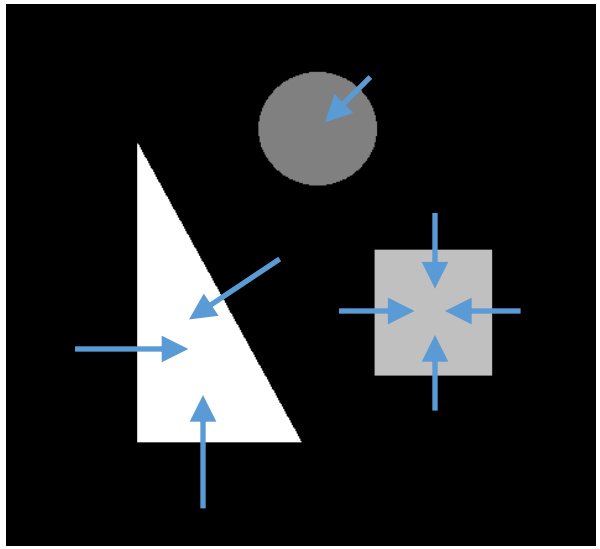




https://de.freepik.com/fotos-vektoren-kostenlos/barcode

Kanten

- Begrenzen Objekte
- Örtliche Änderung der Intensität → Ableitung (in 2D: Gradientenvektor)
  - Stärke der Änderung: Betrag des Gradientenvektors
  - Richtung des Vektors



Diskrete Ableitungen

- Diskretes Pixelgitter
  Ableitung wird durch Differenzen-Quotienten angenähert

- Erste Ableitung

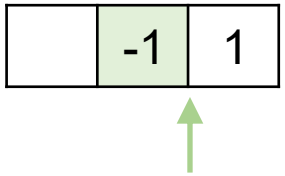
Vorwärts-Differenzenquotient

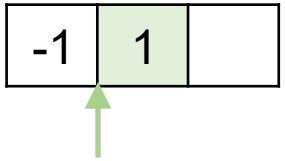
$$\frac{\partial I(x)}{\partial x} \approx \frac{\Delta I(x)}{\Delta x} = I(x+1) - I(x)$$

Rückwärts-Differenzenquotient

$$\frac{\partial I(x)}{\partial x} \approx \frac{\Delta I(x)}{\Delta x} = I(x) - I(x-1)$$

Filter-Kernel





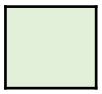
- Ort des Gradienten  relativ zum Zentralpixel 
  um ½ Pixel vorwärts/rückwärts verschoben
  → in Praxis selten verwendet

Diskrete Ableitungen

- Erste Ableitung, Zentraler Differenzenquotient

$$\frac{\partial I(x)}{\partial x} \approx \frac{\Delta I(x)}{\Delta x} = \frac{1}{2}[I(x+1) - I(x-1)]$$

- Ort des Gradienten ↑ mittig auf Zentralpixel
  → in Praxis bevorzugt



Filter-Kernel

$\frac{1}{2} \cdot$ | -1 | 0 | 1 |

Diskrete Ableitungen

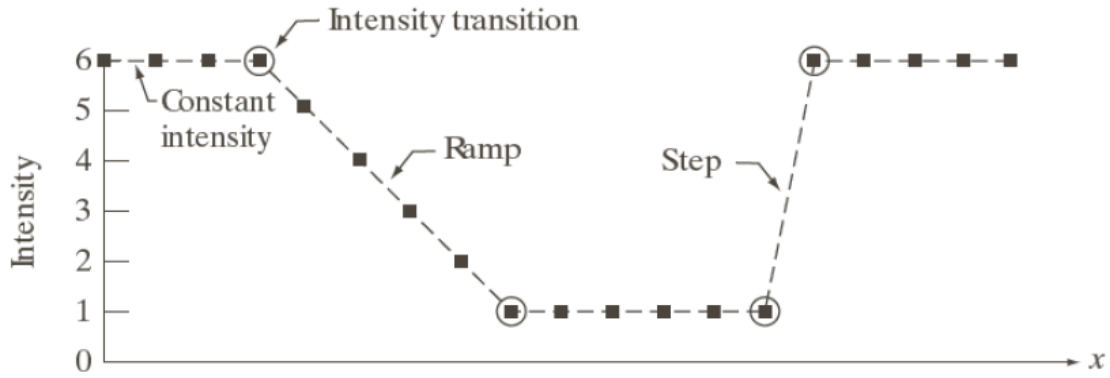
- Zweite Ableitung

$$\frac{\partial^2 I(x)}{\partial x^2} \approx \frac{\partial I(x)}{\partial x} - \frac{\partial I(x-1)}{\partial x} = [I(x+1) - I(x)] - [I(x) - I(x-1)]$$
$$= I(x+1) - 2I(x) + I(x-1)$$

Filter-Kernel

1	-2	1

Kantendetektion



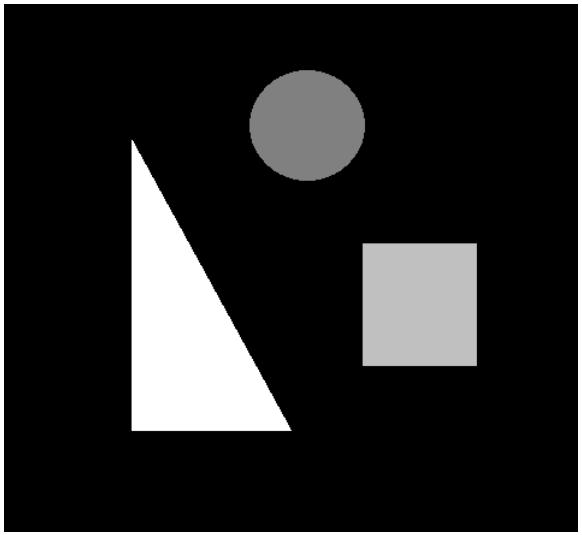
Scan line	6	6	6	6	5	4	3	2	1	1	1	1	1	1	6	6	6	6	6	x
1st derivative	0	0	−1	−1	−1	−1	−1	0	0	0	0	0	5	0	0	0	0			
2nd derivative	0	0	−1	0	0	0	0	1	0	0	0	0	5	−5	0	0	0			

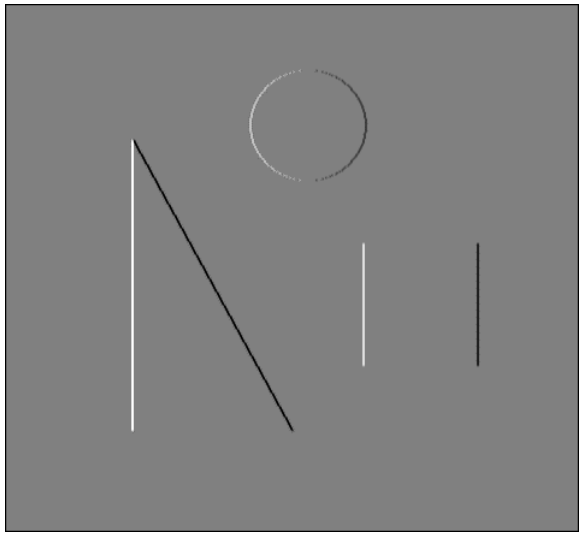
Diskrete Ableitungen in 2D

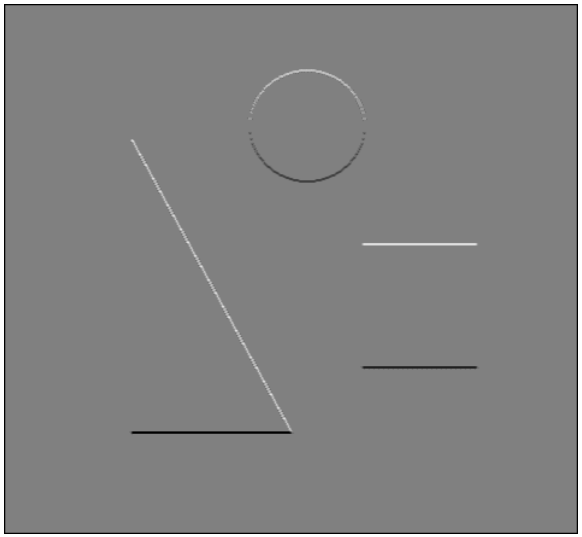
$$\vec{\nabla} I = \begin{pmatrix} I_x \\ I_y \end{pmatrix}$$

$$I_x = \begin{array}{|c|c|c|} \hline -1 & 0 & 1 \\ \hline \end{array}$$

$$I_y = \begin{array}{|c|} \hline -1 \\ \hline 0 \\ \hline 1 \\ \hline \end{array}$$









0 255



-255 +255

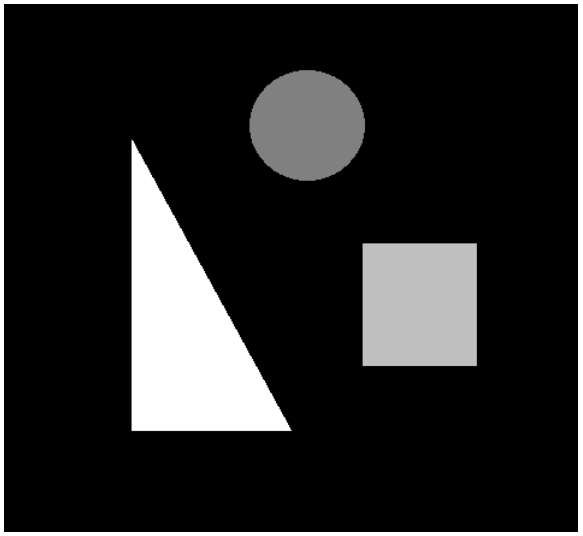
Diskrete Ableitungen in 2D

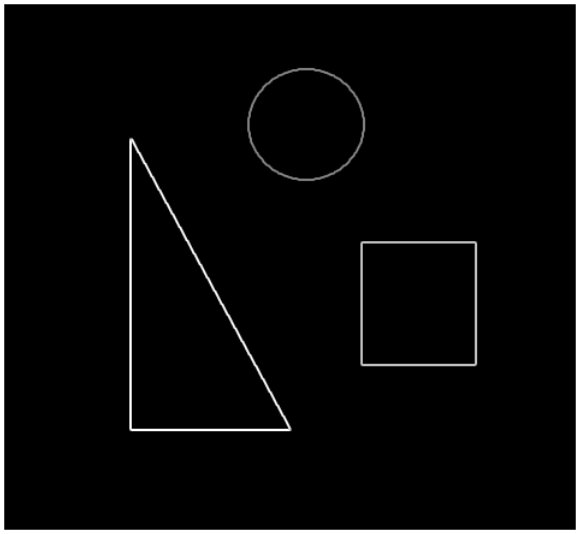
Betrag des Gradienten

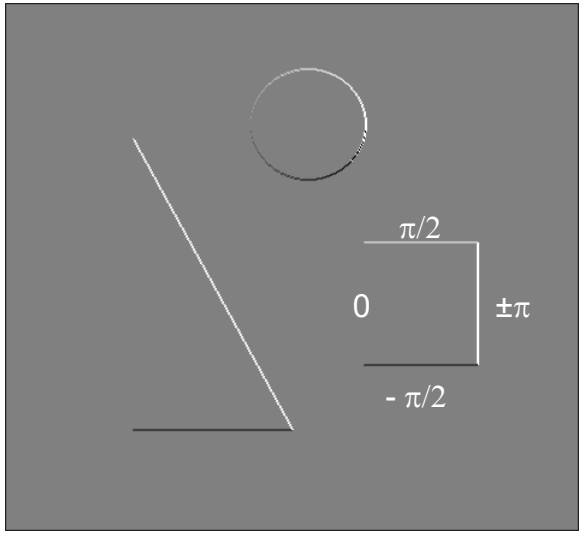
$$|\vec{\nabla} I| = \sqrt{I_x^2 + I_y^2}$$

Richtung des Gradienten

$$arc\,\vec{\nabla} I = atan2(I_y\,, I_x\,)$$







0 255 0 255 -π +π

Diskrete Ableitungen

- Kantendetektoren sind Hochpass-Filter
  → Verstärkung von hohen Frequenzen und damit des Rauschens !!
  → Kombination mit Tiefpassfilter (z.B. Mittelwertfilter) sinnvoll

- Prewitt-Operator
  Zentrale Differenzen in y; Mittelwert in x (und umgekehrt)

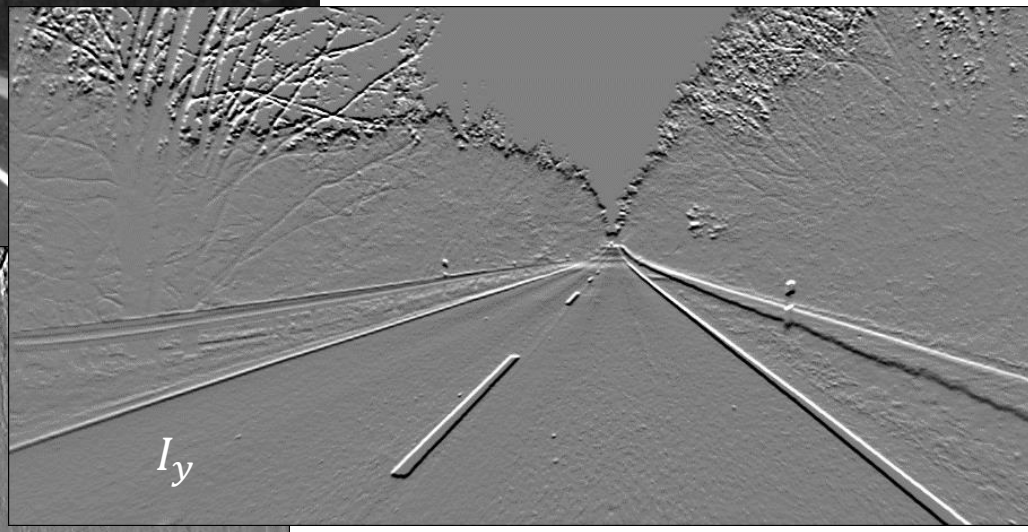
-1				-1	-1	-1		-1	0	1
0	*	1	1	1	=	0	0	0	bzw.	-1	0	1
1						1	1	1		-1	0	1

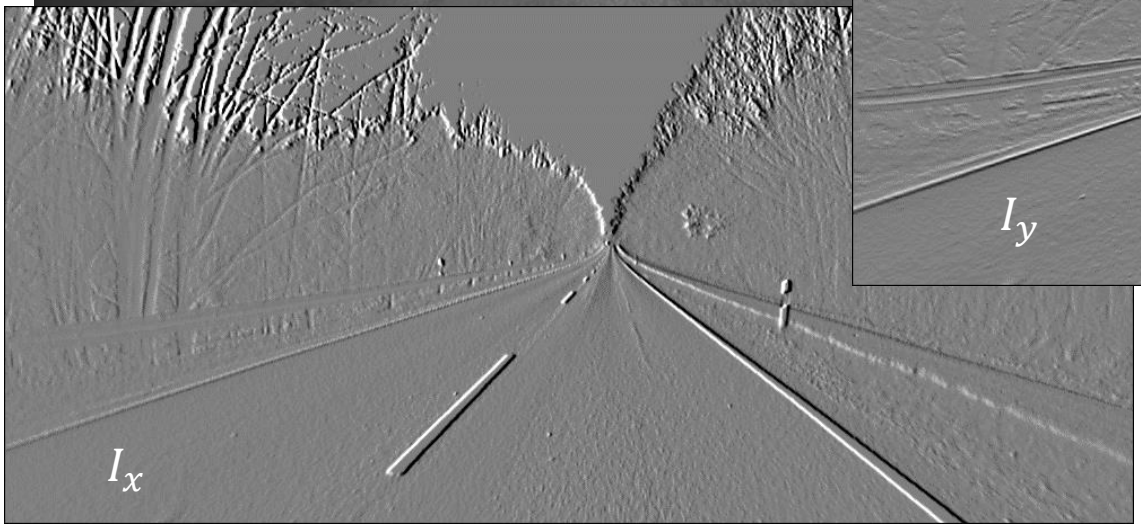
- Sobel-Operator
  Zentrale Differenzen in y; Binomial-Filter B_3 in x (und umgekehrt)

-1				-1	-2	-1		-1	0	1
0	*	1	2	1	=	0	0	0	bzw.	-2	0	2
1						1	2	1		-1	0	1

Anwendung: Spurhalte-Assistenzsystem







Canny-Edge-Detection

Algorithmus zur Detektion und Verkettung von Kantenpixeln

4 Schritte

1) Bild mit Gauß-Filter entrauschen
2) Intensitäts-Gradienten berechnen (z.B. mit Sobel-Operator)
3) Non-maximum suppression, um Zentrum der Kante zu finden
4) Doppeltes Thresholding, Verfolgen aller Kanten mit Hysterese

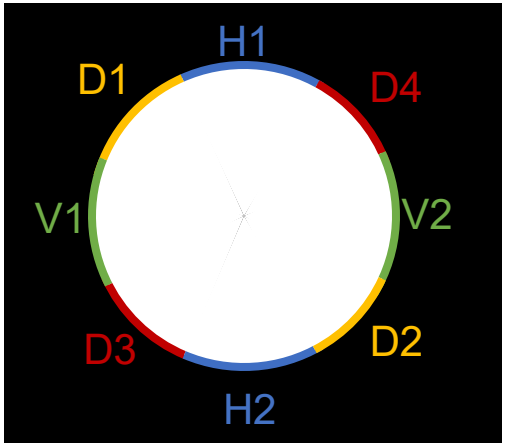
Canny-Edge-Detection

1) Entrauschen mit Tiefpass-Filter
   - Rauschen kann die Kantenerkennung leicht beeinträchtigen
     → Verrauschte Kantenposition („Zickzack-Linien“)
   - Bild mit Tiefpass filtern, z.B. Gauß-Filter oder Binomial-Filter
     → Breite des Kernels beeinflusst die Dichte an gefundenen Kanten

Canny-Edge-Detection

2) Intensitäts-Gradienten
   - Berechne Gradienten I_x und I_y
   - Berechne Betrag des Gradientenvektors
   - Berechne Winkel des Gradienten, Diskretisierung auf 8 Werte

- Vertikale Kanten V1/V2:
  -22,5° … 22,5° → ≈ 0° (+180°) → 0; 4
- Diagonale Kanten D1/D2:
  22,5° … 67,5° → ≈ 45° (+180°) → 1; 5
- Horizontale Kanten H1/H2:
  67,5° … 112,5° → ≈ 90° (+180°) → 2; 6
- Diagonale Kanten D3/D4:
  112,5° … 157,5° → ≈ 135° (+180°) → 3; 7



Canny-Edge-Detection

3) Non-maximum suppression
   - Finden der Pixel mit stärkstem Gradienten
   - 3x3 Nachbarschaft betrachten
     - unterdrücke Pixel, wenn einer der Nachbarn ‚x' einen stärkeren Gradienten hat

x	-	x
x	-	x
x	-	x

Vertikale Kante
V1/V2

x	x	x
-	-	-
x	x	x

Horizontale Kante
H1/H2

x	x	-
x	-	x
-	x	x

Diagonale Kante
D1/D2

-	x	x
x	-	x
x	x	-

Diagonale Kante
D3/D4

Canny-Edge-Detection

4) Doppelter Schwellwert

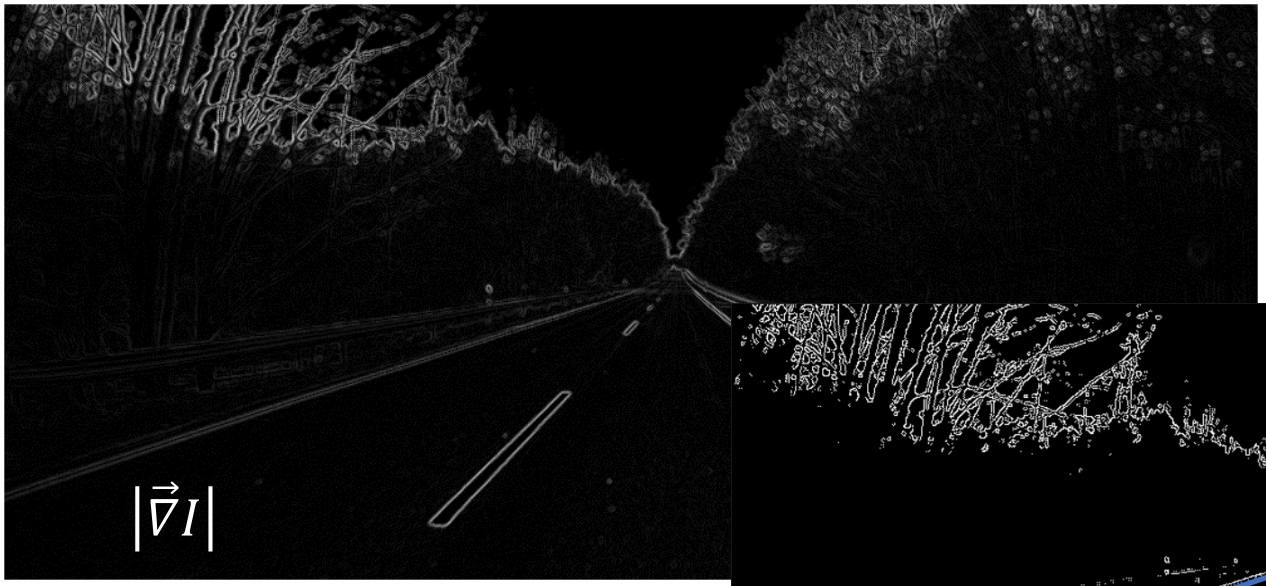
Wahl von zwei Schwellwerten T_1, T_2, wobei $T_1 > T_2$

starke Kantenpixel: $|\vec{\nabla} I| \geq T_1$
schwache Kantenpixel: $T_1 > |\vec{\nabla} I| \geq T_2$

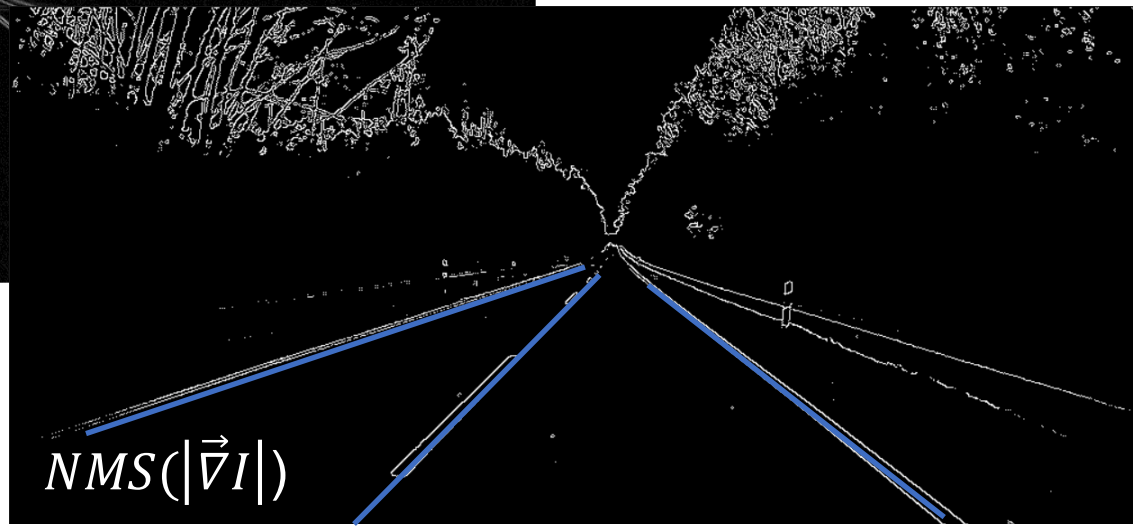
Hysterese

schwache Kantenpixel werden unterdrückt, wenn sie keine Verbindung zu starken Kantenpixeln haben

Canny-Edge-Detection



Gradientenbild



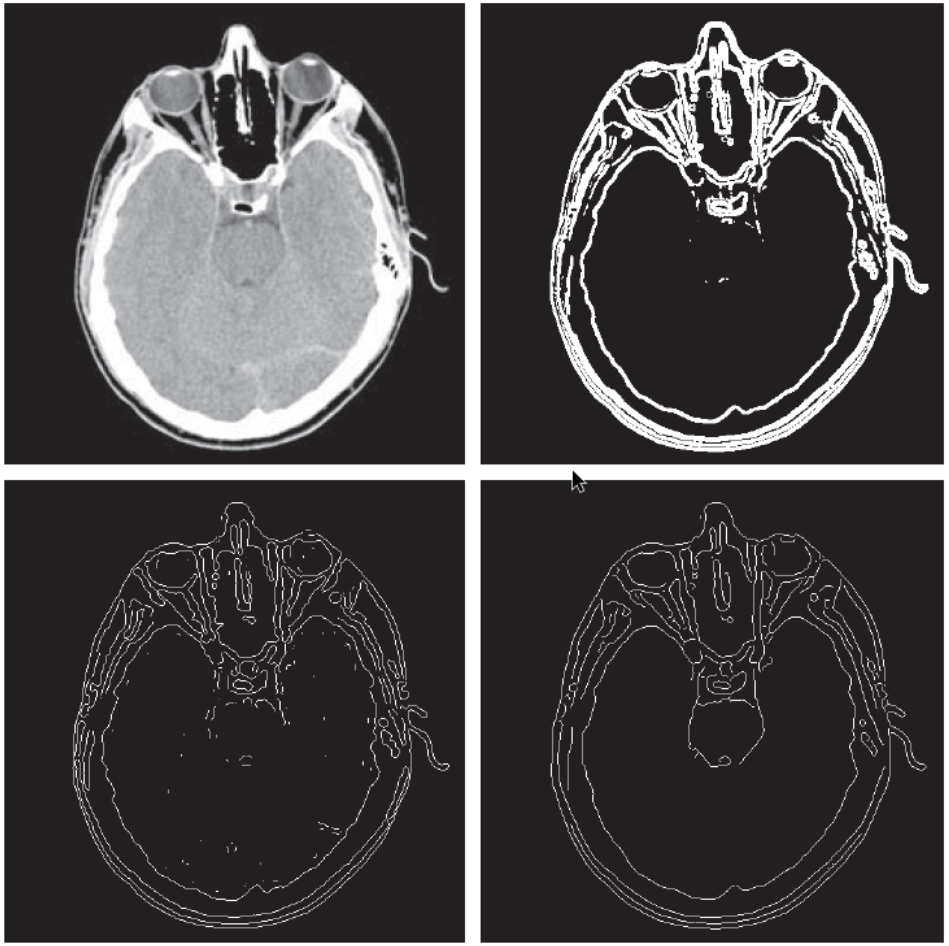
Non-maximum suppression
und Thresholding

Post-processing + Tracking

Canny-Edge-Detection

a b
c d

FIGURE 10.26
(a) Head CT image of size 512×512 pixels, with intensity values scaled to the range [0, 1].
(b) Thresholded gradient of the smoothed image.
(c) Image obtained using the Marr-Hildreth algorithm.
(d) Image obtained using the Canny algorithm.
(Original image courtesy of Dr. David R. Pickens, Vanderbilt University.)

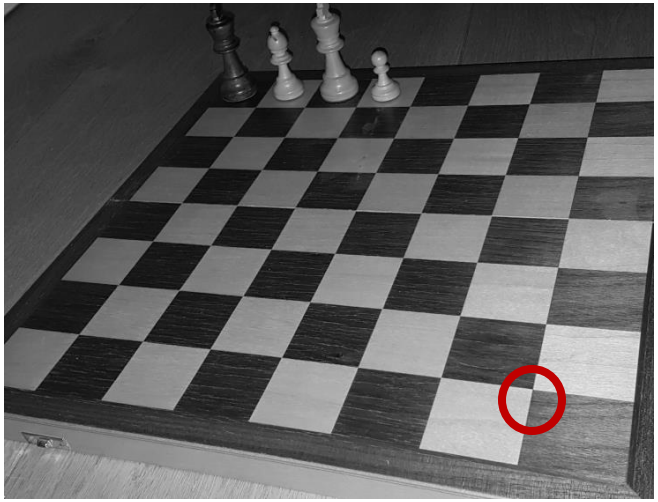


Ecken

Bildpunkt in denen sich zwei Kanten aus unterschiedlichen Richtungen treffen.
Punkte höchster Informationsdichte.

Anwendungen

- Objekt-Tracking
- Image stitching
- Kamera-Kalibrierung



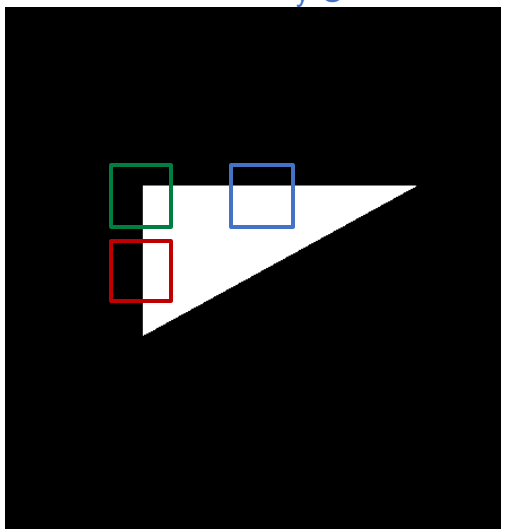


Harris corner detector

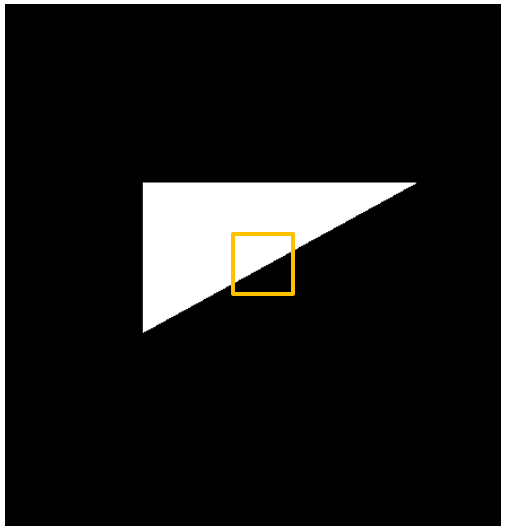
Vorüberlegungen

Ecke
I_x groß
I_y groß

Horizontale Kante
I_x klein
I_y groß



Vertikale Kante
I_x groß
I_y klein



Diagonale Kante
I_x groß
I_y groß

→ Haupt-Achsentransformation der Ableitungswerte, um unabhängig von der Orientierung der Kante im Bild zu werden!

→ Eigenwert-Betrachtung der Gradienten

Harris corner detector

Haupt-Achsentransformation

der Harris-Matrix

$$M(x,y) = \begin{pmatrix} I_x^2 & I_x I_y \\ I_x I_y & I_y^2 \end{pmatrix}$$

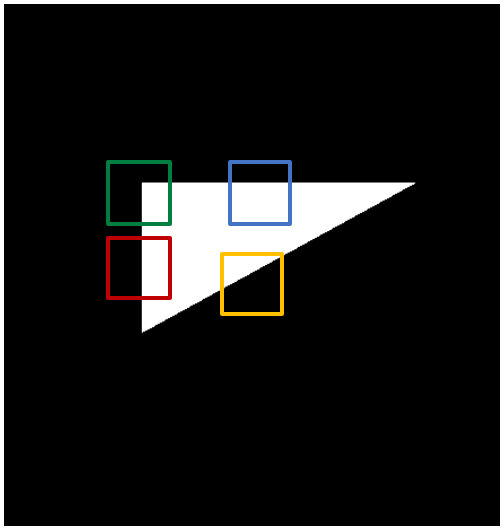
Eigenwerte λ_1, λ_2 von *M*

mit $\lambda_1 \geq \lambda_2 \geq 0$

→ Eckendetektion unabhängig von Orientierung der Kanten und Ecken möglich.

Ecke
λ_1 groß
λ_2 groß

Horizontale Kante
λ_1 groß
λ_2 klein



Vertikale Kante
λ_1 groß
λ_2 klein

Diagonale Kante
λ_1 groß
λ_2 klein

Harris corner detector

Einfacher und robuster Eckendetektor

Eigenschaften

- Gute Invarianz bezüglich Illumination und Rotation
- Nicht invariant bezüglich Skalierung

Algorithmus

1. Umwandeln in Graubild
2. Berechnen der Gradientenbilder I_x und I_y
3. Berechnung der Eigenwerte λ_1, λ_2 der Harris-Matrix M
4. Berechnung der Eckenstärke
5. Thresholding und non-maximum Unterdrückung

Chris Harris and Mike Stephens (1988). "A Combined Corner and Edge Detector". Alvey Vision Conference. 15.

Harris corner detector

1. Vorverarbeitung

   Umwandeln in Graubild → spätere Vorlesung
   Glättung mit Gauss-Filter
2. Berechnen der Gradientenbilder I_x und I_y

   Faltung mit Sobel-Operator

Harris corner detector

3. Berechnung der „Harris Matrix“ M für jeden Pixel (x, y)

$$M(x,y) = \begin{pmatrix} I_x^2 & I_x I_y \\ I_x I_y & I_y^2 \end{pmatrix}$$

Glättung der quadratischen Gradientenbilder!

4. Berechnung der Eckenstärke

$$C(x,y) = \lambda_1 \lambda_2 - k \cdot (\lambda_1 + \lambda_2)^2$$

mit k = 0.04..0.06

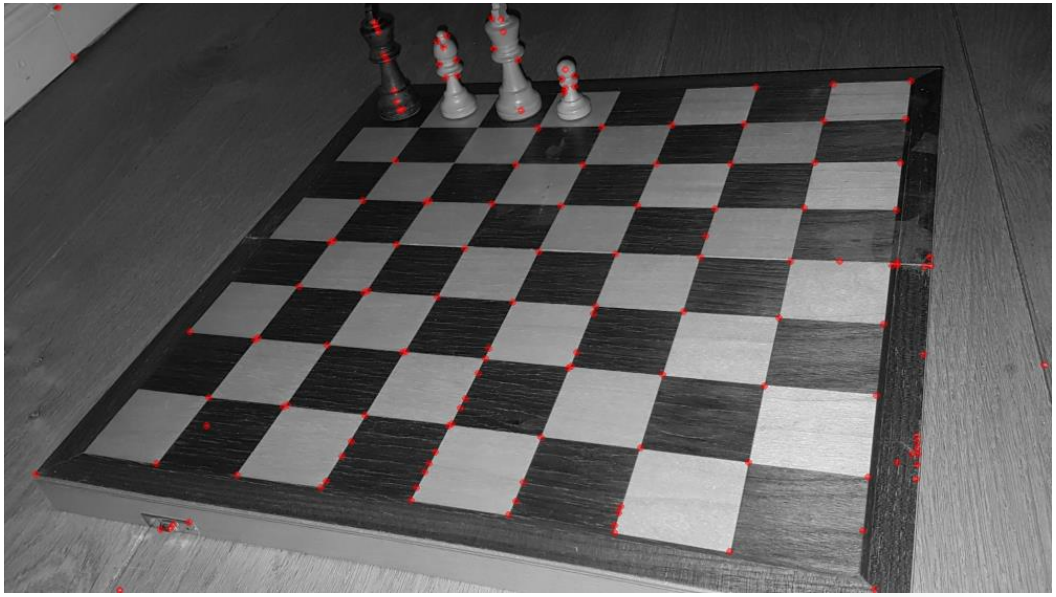
Eine explizite Berechnung der Eigenwerte ist nicht nötig, da:

$$\lambda_1 \lambda_2 = \det(M) = I_x^2 \cdot I_y^2 - (I_x \cdot I_y)^2$$

$$\lambda_1 + \lambda_2 = trace(M) = I_x^2 + I_y^2$$

5. Thresholding und non-maximum Unterdrückung

Harris corner detector



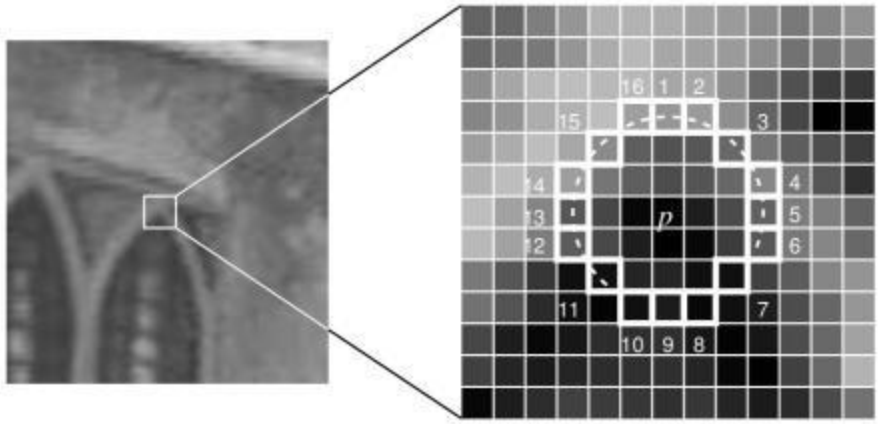


FAST: Features from accelerated segment test

Problem: Harris corner detection zu *langsam* für Echtzeit-Anwendungen, wie z.B. Online-Lokalisierung mit mobilen Robotern

Grundidee FAST

- Betrachte Kreis aus 16 Pixeln um Testpixel *p.*
- Wähle Schwellwert *t*
- *p* ist eine **Ecke**, wenn davon 12 zusammenhängende Pixel
  a) heller: $I_i > I_p + t$
  b) dunkler: $I_i < I_p - t$
  sind.



- **High-Speed-Test** um so wenige Nachbar-Pixel wie möglich zu prüfen
- **Entscheidungsbaum** (decision tree classifier) *optional* zur Verbesserung

E. Rosten, T. Drummond: "Machine Learning for High-speed Corner Detection". ECCV 2006
https://commons.wikimedia.org/wiki/File:FAST_Corner_Detector.jpg

FAST: High-speed test

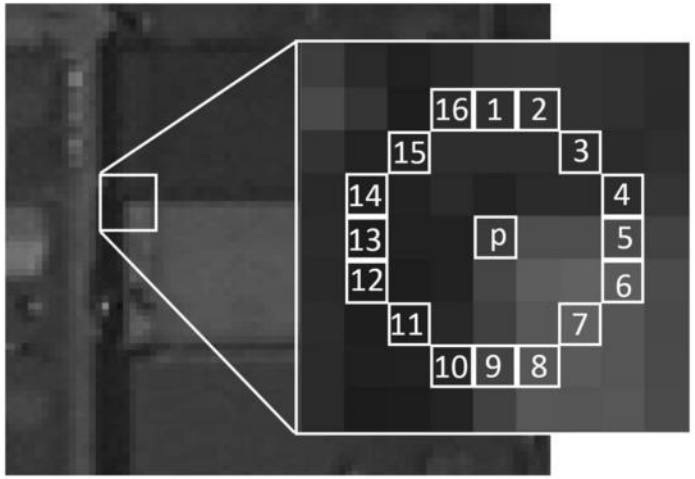
1. **Überprüfung: weder Pixel 1 noch Pixel 9 deutlich heller oder dunkler als p ?**
   wenn $I_1 \in [I_p - t, I_p + t]$ und $I_9 \in [I_p - t, I_p + t]$ → keine Ecke (~90% aussortiert)

2. **Überprüfung: sind mindestens 3 der Pixel 1, 5, 9 und 13 deutlich heller oder dunkler?**
   wenn 3 Pixel $\in \{I_1, I_5, I_9, I_{13}\} < I_p - t$ oder $> I_p + t$ → Ecken-Kandidat

3. **Volle Überprüfung**
   sind 12 zusammenhängende Pixel heller oder dunkler als p ?

Schwächen von FAST

- viele Zusammenhängende Ecken
→ non-maximum Suppression



E. Rosten, T. Drummond: "Machine Learning for High-speed Corner Detection". ECCV 2006
https://commons.wikimedia.org/wiki/File:FAST_Corner_Detector.jpg

FAST: Machine-Learning Corner Detector

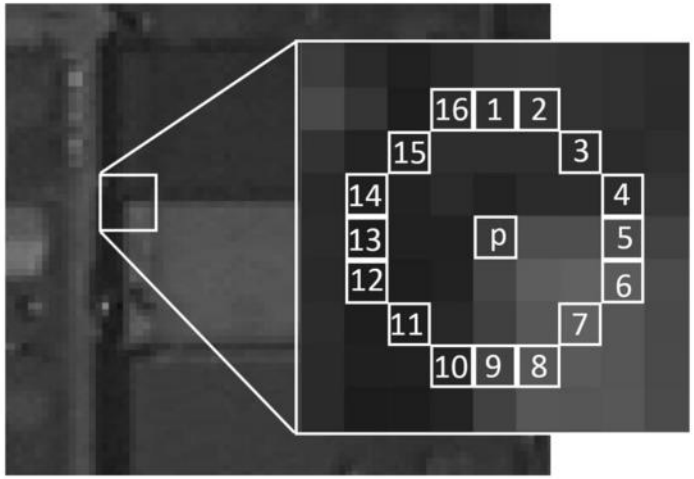
1. **Training eines Entscheidungsbaums auf Trainingsbildern**
   (ähnliche Szene [Kamera, Ort, Beleuchtung, …] wie in der Endanwendung)
   1. Ecken-Kandidaten mit FAST bestimmen
   2. 16 Nachbarpixel als Vektor speichern
   3. …
   4. Training eines Entscheidungsbaums anhand von manuellen Labels {wahr, falsch}

Vorteile des Classifiers

- höhere Genauigkeit, robuster gegenüber Rauschen

Nachteile des Classifiers

- Training ist aufwändig
- langsamer



https://docs.opencv.org/3.4/df/d0c/tutorial_py_fast.html

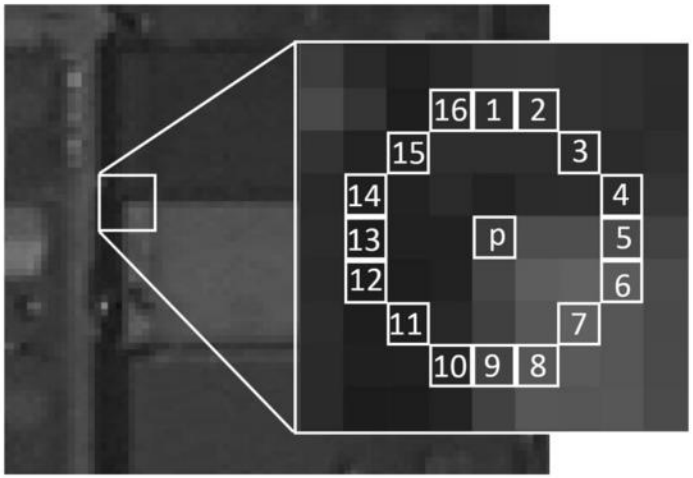
Features from accelerated segment test (FAST)

- recheneffizienter Eckendetektor
  (22x schneller als Harris-Corner-Det.)
  → real-time Video-Verarbeitung

- weitere Verbesserung mit anwendungs-spezifischem Machine-Learning Ansatz

- Non-maximum suppresion
  benötigt um viele eng benachbarte Ecken zu vermeiden

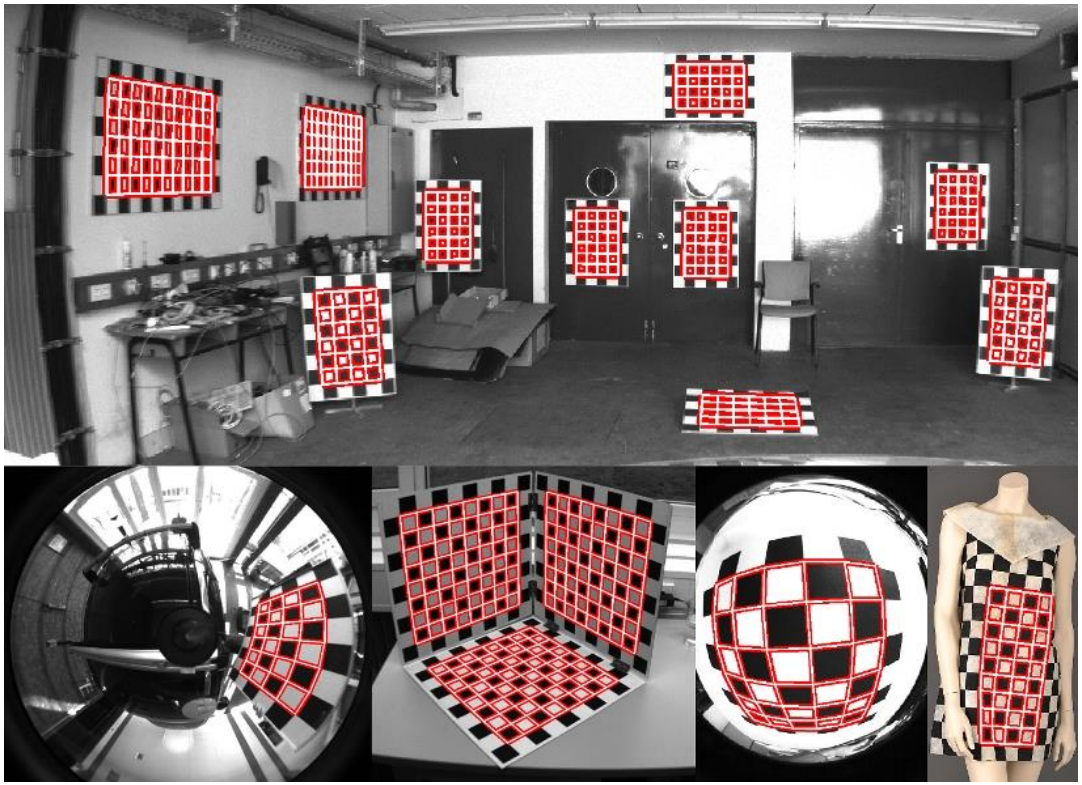
- Nicht robust bei starkem Rauschen
- Abhängig von Wahl des Thresholds



E. Rosten, T. Drummond: "Machine Learning for High-speed Corner Detection". ECCV 2006
https://commons.wikimedia.org/wiki/File:FAST_Corner_Detector.jpg

Anwendungen der Eckendetektion

Vermessung von Messfeldern für Kamera-Kalibrierung



A. Geiger, http://www.cvlibs.net/software/libcbdetect/

Anwendung: Image Stiching

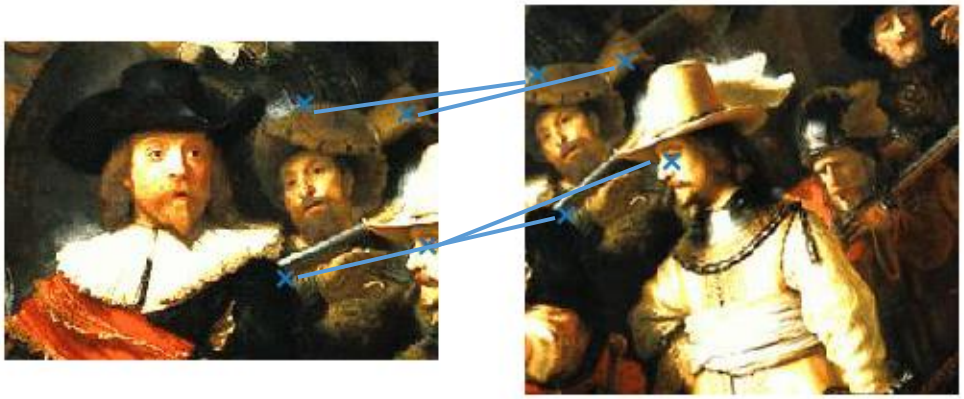




1. Finden von Eckpunkten

https://staff.fnwi.uva.nl/r.vandenboomgaard

Anwendung: Image Stiching



1. Finden von Eckpunkten
2. Finden von „ähnlichen Pixelpaaren“ (Korrespondenzen)
   - Deskriptor: Beschreibt Eigenschaften der Nachbarschaft der Ecke
   - Paarweiser Vergleich der Deskriptoren aller Ecken in beiden Bildern
3. RANSAC (*random sample consensus*) um passende Paare zu finden

https://staff.fnwi.uva.nl/r.vandenboomgaard

Anwendung: Image Stiching



1. Finden von Eckpunkten
2. Finden von „ähnlichen Pixelpaaren“ (Korrespondenzen)
3. RANSAC (*random sample consensus*) um passende Paare zu finden
4. Geometrische Transformation eines der Bilder
5. Überlagerung / Blending

https://staff.fnwi.uva.nl/r.vandenboomgaard

Überblick Feature-Deskriptoren

Scale-invariant feature transform (SIFT) [D. Lowe 2004]
- approximiert lokale zweite Ableitung mit Laplacian-of-a-Gaussian (LoG)
- für mehrere Auslösungsstufen (Pyramide)
- in verschiedene Richtungen

Speeded Up Robust Features (SURF) [H. Bay, et al. 2006]
- approximiert lokale zweite Ableitung mit Box-Filtern
- effiziente Berechnung auf Integralbild

Binary Robust Independent Elementary Features (BRIEF) [M. Calonder et al., 2010]
- reiner Feature Deskriptor
- sehr kompakt durch binäre Punktvergleiche

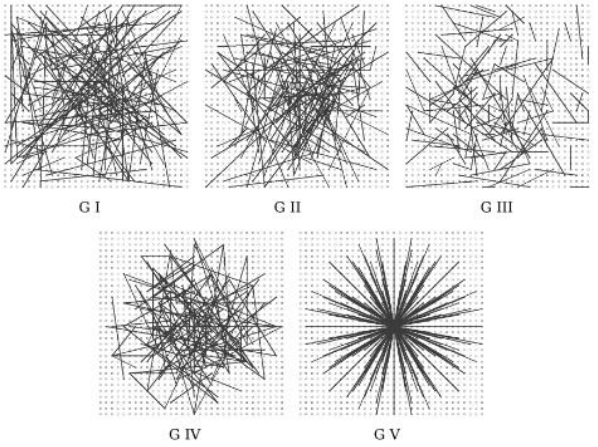
Oriented FAST and rotated BRIEF (ORB) [E. Rublee et al, 2011]
- zusätzliche Orientierung in BRIEF
- Patent-frei
- weite Verbreitung in Video-Mapping und Lokalisierung (ORB-SLAM)

Binary Robust Independent Elementary Features (BRIEF)

- BRIEF ist ein reiner Deskriptor (*feature descriptor*)
- Ecken müssen vorher mit einem anderen Verfahren (Harris, FAST, …) detektiert werden

1. Glättungsfilter auf Bild anwenden
2. Für jede Ecke:
   - nehme lokalen Bildausschnitt
   - wähle *N* Pixelpaare (p_i, q_i), z.B. $N = 256$
   - fülle einen binären Vektor x der Länge N:

$$x(i) = 1 \text{ falls } I(p_i) < I(q_i), \text{ 0 sonst}$$

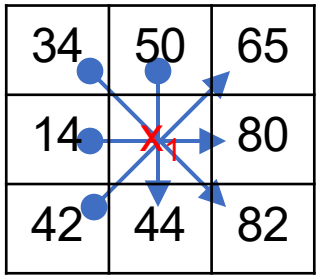


Mögliche Punktpaare:
- vorab ein Muster festlegen
- zufällige Paare oft besser

M. Calonder et al., BRIEF: Binary Robust IndependentElementary Features, ECCV 2010

Übungsaufgabe: Finden der Brief-Deskriptoren

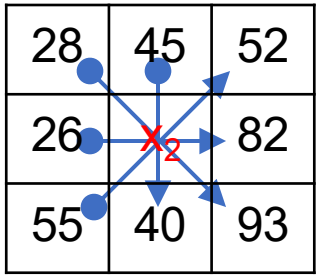
- Gegeben: Pixel-Intensitäten der 3x3 Nachbarschaft einer Ecke x_1
- Gesucht: Deskriptor = (Pixel_start > Pixel_end)



4-Bit Deskriptor



- Gegeben: Zweiter Eckpunkt x_2
- Frage: Sind sich die beiden Ecken "ähnlich" ? → Sind sich die Deskriptoren ähnlich?



4-Bit Deskriptor



Binary Robust Independent Elementary Features (BRIEF)

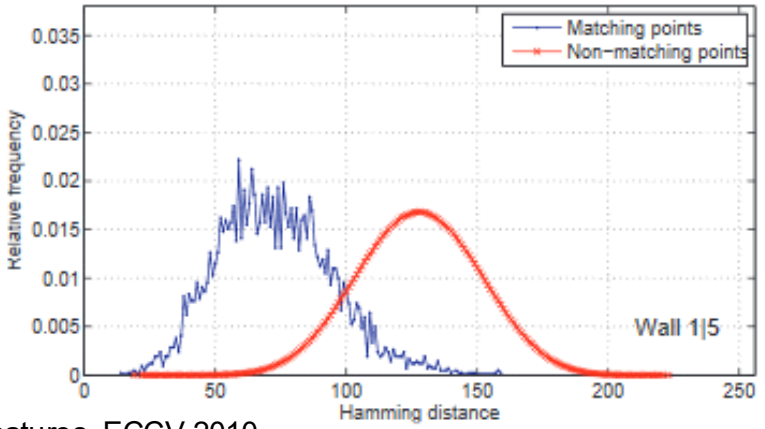
Distanzmaß für die Ähnlichkeit zweier Ecken

Hamming distance d der Feature Deskriptoren x_1 und x_2:

$d(x_1, x_2) = \text{bitsum}(x_1 \text{ XOR } x_2)$

→ hocheffizient zu berechnen

x_1	0	1	1	0	1	0	1	0
x_2	0	1	0	1	1	0	1	1
$d(x_1, x_2) = 3$	0	0	1	1	0	0	0	1



M. Calonder et al., BRIEF: Binary Robust IndependentElementary Features, ECCV 2010

Eliminieren von falschen Korrespondenzen

Gegeben: Zwei Bilder mit

- Feature-Punkten mit Deskriptoren
- Ähnlichkeitsmaße für alle Punktpaare (z.B. Hamming distance)

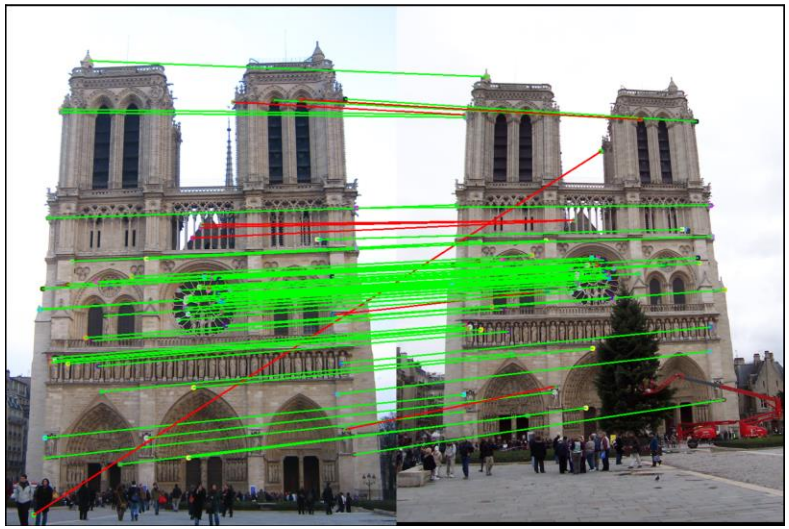
Lowe‘s ratio test

Verwerfe unsichere Korrespondenzen

1. Finde für jeden Punkt *p* im Quellbild die besten 2 Korrespondenzpunkte q_1 und q_2 im Zielbild
2. Behalte die Korrespondenz (p,q_1) nur, falls:

$$dist(p, q_1) < t \cdot dist(p, q_2)$$

t : Schwellwert (z.B. t = 0.5)



https://www.cc.gatech.edu/~hays/compvision/proj2/proj2.pdf

Finden der Transformation zwischen zwei Bildern

Gegeben: Zwei Bilder mit

- Feature-Punkten mit Deskriptoren
- Ähnlichkeitsmaße für alle Punktpaare (z.B. Hamming distance)

Gesucht: Transformation T: $x_{img2} \rightarrow x_{img1}$

RANSAC (*random sample consensus*)

1. Suche Punkt-Paare mit guter Ähnlichkeit
2. Wähle daraus n_{pp} zufällige Punktpaare
3. Berechne daraus Transformation T
4. Berechne Fehler von T
   für die n_{pp} Punktpaare mit (x_1,x_2):
   Fehler += $|| x_1 - T(x_2) ||$
5. Wiederhole 2. - 4. beliebig oft
6. gebe Transformation T_{opt} mit
   kleinstem Fehler zurück

Anwendungen der Eckendetektion

Image stitching

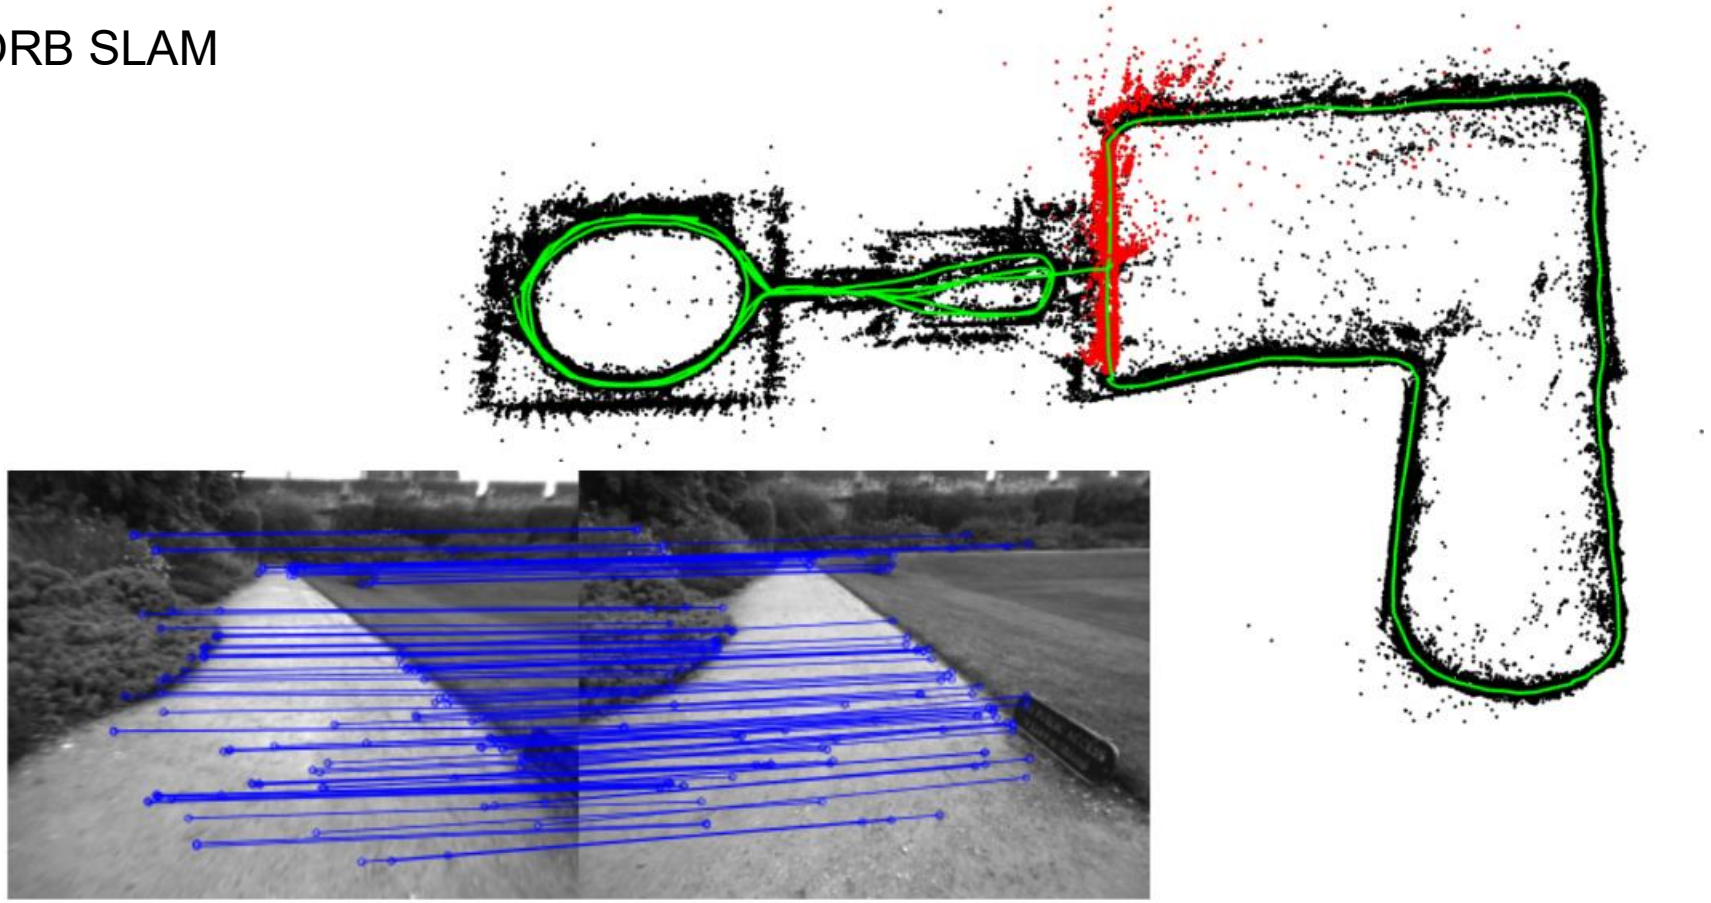




Chen et al., Natural Image Stitching with the Global Similarity Prior, ECCV 2016

Anwendungen der Eckendetektion

ORB SLAM



R. Mur-Artal et al., ORB-SLAM: a Versatile and Accurate Monocular SLAM System, IEEE TR 2015

Nächste Vorlesung:

Farbwahrnehmung

- beim Menschen und im Bildsensor

Farbräume

- RGB
- CMY / CMYK
- HSI
- CIE LAB

Farbbilder

- Falschfarbendarstellung
- Color-Balancing

Ende der Vorlesung

–

Fragen ?